

MÁSTER EN DATA SCIENCE & AI
EVOLVE

TRABAJO FIN DE MÁSTER

Sistema de apoyo a la planificación hospitalaria basado en datos reales del SNS

*Un índice estructural de presión asistencial por patología y comunidad autónoma, construido y
validado sobre datos públicos abiertos del INE y el Ministerio de Sanidad*

Autora

Irene Rodríguez Sánchez

Curso académico

2025-2026

Madrid

Resumen

Los hospitales del Sistema Nacional de Salud (SNS; Ley 16/2003, 2003) gestionan de forma mayoritariamente reactiva la planificación de su capacidad asistencial, sin herramientas basadas en datos reales que permitan comparar de forma objetiva dónde se concentra la presión asistencial entre patologías y territorios. Este Trabajo Fin de Máster valida, ficha a ficha, ocho fuentes públicas del Instituto Nacional de Estadística (INE, 2024) y el Ministerio de Sanidad (2025) y confirma un hallazgo que determina todo el diseño del proyecto: ninguna de ellas cruza simultáneamente diagnóstico, territorio y tiempo. A partir de esa limitación -tratada como resultado, no como nota al margen- se acota el alcance a un único MVP: un índice estructural de presión asistencial por patología y comunidad autónoma para el año 2023, complementado con un bloque descriptivo de tendencia nacional 2014-2023.

Siguiendo la metodología CRISP-DM (Chapman et al., 2000), se construye una capa de datos integrada (360 combinaciones patología × comunidad autónoma, sin valores nulos, validada contra la cifra oficial de altas con una desviación del 0,11%) y se entrena un modelo de corte transversal (Gradient Boosting Regressor; Friedman, 2001, con Ridge como alternativa lineal de contraste; Hoerl y Kennard, 1970) para explicar la variable altas por cama en funcionamiento. La validación cruzada, ejecutada bajo tres esquemas distintos -K-Fold simple, y GroupKFold por patología y por comunidad autónoma, este último necesario por la estructura pseudorreplificada de los datos (Hurlbert, 1984; Roberts et al., 2017)-, revela un hallazgo central: la mejora del modelo sobre un baseline simple, que parecía sustancial (+8,6% de MAE) bajo una validación ingenua, se reduce a un +0,7% marginal cuando se fuerza al modelo a generalizar a territorios nunca vistos. El índice separa patologías con solidez -dominadas por su perfil clínico nacional (tasa de fallecimiento, de traslado, de urgencia y estancia media)-, pero no sostiene, con la evidencia disponible, una capacidad predictiva territorial robusta. Esta revisión crítica, y no una cifra optimista de partida, se documenta como el resultado principal de la evaluación.

El proyecto se completa con el diseño de un dashboard de priorización para dirección médica y gestión de camas, comunicado explícitamente como panel descriptivo y no como herramienta predictiva ni clínica individual, y con el diseño conceptual -no implementado- de dos módulos descartados por falta de fuente real (riesgo de reingreso a 30 días y presión de derivación multianual), condicionados a la disponibilidad futura de fuentes con mayor granularidad. El trabajo se entrega íntegramente reproducible, con scripts y notebooks de Google Colab ejecutados sin errores sobre datos reales.

Palabras clave

Sistema Nacional de Salud, planificación hospitalaria, presión asistencial, CRISP-DM, ciencia de datos en salud, datos públicos abiertos, corte transversal, Gradient Boosting, validación cruzada por grupos, explicabilidad (SHAP), reproducibilidad, limitaciones de granularidad de datos

Índice

Resumen	2
Palabras clave	3
Índice.....	¡Error! Marcador no definido.
1. Comprensión del negocio (Business Understanding).....	7
1.1 Contexto: gestión en el SNS.....	7
1.2 Problema que se aborda y quién lo usa	7
1.3 Objetivos del TFM	7
1.4 Alcance del MVP y justificación	8
1.5 Criterios de éxito del proyecto	8
2. Comprensión de los datos (Data Understanding)	10
2.1 Inventario de fuentes disponibles	10
2.2 Validación de granularidad real.....	10
2.3 Estructura y exploración de cada fichero	11
2.4 Calidad de los datos.....	12
2.5 EDA de la serie anual nacional 2014-2023	12
Tabla resumen de la serie 2014 - 2023	13
Evolución de las altas hospitalarias totales	13
Estancia media e índice de ocupación	14
Dotación de camas: públicas frente a privadas	14
Urgencias hospitalarias atendidas	15
2.6 EDA de la foto 2023	16
2.7 Conclusión de la fase.....	21
3. Preparación de los datos (Data Preparation).....	22
3.1 Selección de tablas y campos finales por dataset	22
3.2 Limpieza: tipado, valores "." y nulos, normalización de nombres de CCAA/provincia, snake_case.....	22
3.3 Integración: cruce de Alta_Diagnostico_Provincia con Tablas_CCAA_2023 a nivel de CCAA.....	23
3.4 Variables derivadas.....	24
3.5 Limitación documentada: Alta_Motivo_ingreso (traslados/fallecimiento) solo a nivel nacional	25
3.6 Capa gold final: datasets, diccionario de datos y claves primarias	25
3.7 Qué se descarta y por qué.....	26
3.8 Validación visual de la capa gold	26
4. Modelado (Modeling).....	28
4.1 Planteamiento del índice: variable objetivo, predictoras, y por qué es un modelo de corte transversal	28

4.2 Alternativas de modelo y regla de decisión.....	29
4.3 Bloque de tendencia nacional 2014-2023	29
4.4 Variables descartadas y motivo	30
4.5 Explicabilidad: importancia de variables y factores principales por segmento.....	30
5. Evaluación (Evaluation)	32
5.1 Estrategia de validación: por qué un K-Fold aleatorio simple no basta.....	32
5.2 Métricas y baseline.....	32
5.3 Criterio de aceptación -lectura honesta de los tres esquemas	32
5.4 Revisión crítica: ¿el índice sostiene una conclusión real, o solo confirma patrones ya conocidos?	33
5.5 Riesgos y alternativas.....	34
5.6 Explicabilidad: SHAP, score 0-100 y factores principales por segmento.....	34
6. Despliegue (Deployment)	36
6.1 Dashboard: mapa/ranking de presión asistencial por CCAA y patología (2023) + panel de tendencia nacional 2014-2023	36
6.2 Público objetivo y cómo se comunica el resultado	36
6.3 Mantenimiento y actualización	37
6.4 Extensiones futuras.....	38
7. Conclusiones y limitaciones del TFM	39
7.1 Qué demuestra el proyecto y qué no	39
7.2 Limitaciones de fuente como resultado central del TFM	39
7.3 Líneas futuras	40
Bibliografía.....	41
Anexos	43
Anexo A. Diccionario de datos completo.....	43
A.1. Identificadores y variable base	43
A.2. Contexto estructural de CCAA -hospitales y dotación de camas	43
A.3. Contexto estructural de CCAA -personal.....	44
A.4. Contexto estructural de CCAA -frecuentación e indicadores de hospitalización	44
A.5. Contexto estructural de CCAA -urgencias.....	45
A.6. Contexto nacional por patología (Alta_Motivo_ingreso, Alta_Urgencia_ingreso, Estancia_media).....	45
A.7. Variables derivadas	45
Anexo B. Detalle de las 8 fuentes originales y su ficha técnica (INE/Sanidad)	45
Anexo C. Diseño conceptual no implementado	47
C.1. Por qué se descartan del MVP.....	47
C.2. M2 -Presión de derivación.....	47

C.3. M3 -Riesgo de reingreso a 30 días.....	48
C.4. Riesgos específicos de M2/M3 (conceptual)	49
C.5. Condición general de activación	49

1. Comprensión del negocio (Business Understanding)

1.1 Contexto: gestión en el SNS

La planificación de la demanda asistencial, la derivación entre niveles de atención y la presión sobre las estructuras hospitalarias en el Sistema Nacional de Salud (SNS) se gestionan hoy de forma mayoritariamente reactiva (Ley 16/2003, 2003). Las direcciones médicas y los responsables de gestión de camas disponen de indicadores históricos y agregados, pero no de herramientas que permitan comparar de forma sistemática dónde se concentra la presión asistencial real -por patología y por territorio- para anticipar dónde reforzar recursos.

Esta gestión reactiva no es solo un problema de herramientas: es también, como se ha comprobado en la fase de validación de datos de este TFM, un problema de disponibilidad real de información pública con la granularidad necesaria para automatizar una respuesta operativa (por ejemplo, a nivel semanal o por servicio). El proyecto parte de esa validación como punto de partida honesto, en lugar de asumir una granularidad que las fuentes no ofrecen.

1.2 Problema que se aborda y quién lo usa

Problema: no existe un panel único, basado en datos reales y públicos, que permita comparar de forma objetiva la presión asistencial entre comunidades autónomas y patologías, ni situar la posición de cada territorio frente a la tendencia nacional de la última década.

Usuarios principales:

- Dirección médica de área sanitaria / planificación de red: necesita identificar en qué combinaciones de patología y territorio la presión asistencial es estructuralmente más alta, para priorizar el refuerzo de capacidad.
- Gestión de camas y dotación de recursos: necesita contextualizar la dotación actual (camas, personal) frente al volumen de actividad real de su comunidad.

Decisión que apoya: priorización de dónde reforzar capacidad especializada dentro de una comunidad o entre comunidades, a partir de un índice comparable y explicable, no de una intuición o de series parciales.

1.3 Objetivos del TFM

Objetivo de negocio: ofrecer a la dirección médica y a la gestión de camas un índice comparable de presión asistencial por patología y territorio, que sirva de apoyo a la planificación estructural - no a la operativa diaria.

Objetivo analítico: construir, a partir de datos reales y públicos del INE (2024) y el Ministerio de Sanidad (2025), un índice estructural de presión asistencial (patología × CCAA/provincia, año 2023) mediante un modelo de corte transversal interpretable,

complementado con un bloque descriptivo de tendencia nacional (2014-2023) que contextualice ese índice en el tiempo.

Es importante distinguir ambos objetivos: el objetivo de negocio (ayudar a planificar) es más amplio que lo que el objetivo analítico puede demostrar con los datos disponibles. El proyecto es explícito sobre esa diferencia en todo momento, en lugar de forzar el segundo para que parezca cubrir el primero por completo.

1.4 Alcance del MVP y justificación

El alcance inicial del proyecto contemplaba tres módulos: predicción de demanda (forecasting), presión de derivación entre niveles asistenciales y riesgo de reingreso a 30 días. Tras la validación de las ocho fuentes reales disponibles (INE, 2024; Ministerio de Sanidad, 2025), se comprobó que ninguna ofrece granularidad semanal ni un panel CCAA × varios años simultáneamente. Lo que sí existe, de forma robusta y verificada, es:

- Una serie anual nacional 2014-2023 (evolución de actividad y dotación a nivel país; Ministerio de Sanidad, 2025).
- Una foto transversal del año 2023, con cruce rico de diagnóstico × provincia/CCAA × motivo de alta × estancia media (INE, 2024).

Ante esta limitación real -no asumida, sino verificada fichero a fichero-, el MVP se acota a un único módulo: el índice estructural de presión asistencial sobre la foto de 2023, con la serie 2014-2023 como bloque de tendencia y contexto, no como fuente de forecasting. Los módulos de derivación multianual y riesgo de reingreso quedan documentados como diseño conceptual no implementado (Anexo C), condicionados a la disponibilidad futura de fuentes con la granularidad que hoy no existe públicamente (por ejemplo, iCMBD para reingreso).

Esta decisión de alcance es en sí misma un resultado del proceso de Data Understanding (sección 2), y se presenta como tal: la limitación de fuente no es una nota al margen, sino el hallazgo que determina el diseño del proyecto.

1.5 Criterios de éxito del proyecto

El proyecto se considera útil si:

- El índice de presión asistencial permite discriminar de forma clara entre combinaciones patología × territorio con distinta presión estructural (no todos los valores son parecidos).
- El modelo mejora sobre un baseline simple (media histórica de la tasa por patología, sin distinguir CCAA), demostrando que el territorio aporta información relevante.

- Los factores explicativos del índice son interpretables por un perfil no técnico (dirección médica), no una caja negra (Lundberg y Lee, 2017).
- El proyecto distingue con claridad qué conclusiones sostienen los datos reales disponibles y cuáles quedarían fuera de alcance por falta de fuente (forecasting semanal, reingreso individual).

El proyecto se consideraría fallido, o su alcance debería revisarse, si el índice no logra separar territorios/patologías de forma significativa (es decir, si toda la variabilidad se explica por ruido o por el tamaño de la muestra en cada celda), o si la única forma de sostener alguno de los módulos descartados fuera recurriendo a datos sintéticos - algo que este TFM excluye explícitamente como principio metodológico.

2. Comprensión de los datos (Data Understanding)

2.1 Inventario de fuentes disponibles

El proyecto parte de ocho ficheros públicos del INE (Encuesta de Morbilidad Hospitalaria; INE, 2024) y del Ministerio de Sanidad (Estadística de Establecimientos Sanitarios con Régimen de Internamiento, ESCRI; Ministerio de Sanidad, 2025), correspondientes al ejercicio 2023 salvo dos series históricas 2014-2023:

Fichero	Contenido	Nivel geográfico	Cruces disponibles
Alta_Diagnostico_Provincia.xlsx (INE, 2024)	Altas hospitalarias por diagnóstico principal	Nacional, CCAA y provincia	Diagnóstico × sexo × territorio
Alta_Motivo_ingreso.xlsx (INE, 2024)	Altas por motivo de alta (curación, traslado, fallecimiento, otras)	Nacional	Diagnóstico × sexo × motivo
Alta_Urgencia_ingreso.xlsx (INE, 2024)	Altas por tipo de ingreso (ordinario / urgente)	Nacional	Diagnóstico × sexo × urgencia
Altas_Diagnostico_principal.xlsx (INE, 2024)	Altas por grupo de edad	Nacional	Diagnóstico × sexo × edad
Estancia_media.xlsx (INE, 2024)	Estancia media en días	Nacional	Diagnóstico × sexo × edad
Tablas_CCAA_2023.xlsx (Ministerio de Sanidad, 2025)	Dotación de hospitales, camas, personal, tecnología y actividad diagnóstica	CCAA	Múltiples tablas (1.1 a 7.3) por CCAA
Actividad_Evolucion_2014-2023.xlsx (Ministerio de Sanidad, 2025)	Serie histórica de actividad hospitalaria	Nacional	Año (13 tablas, 2014-2023)
Dotacion_Evolucion_2014-2023.xlsx (Ministerio de Sanidad, 2025)	Serie histórica de dotación y personal	Nacional	Año (10 tablas, 2014-2023)

2.2 Validación de granularidad real

Este es el hallazgo central de la fase de comprensión de datos, y el que determina el alcance del proyecto (ver sección 1.4). La siguiente tabla resume, para cada fuente, qué dimensiones cruza realmente:

Fuente	Frecuencia temporal	Nivel geográfico	Nivel clínico
Alta_Diagnostico_Provincia	Foto única (2023)	CCAA / provincia	Diagnóstico (capítulo y subcapítulo CIE-10)
Alta_Motivo_ingreso	Foto única (2023)	Nacional únicamente	Diagnóstico × motivo de alta
Alta_Urgencia_ingreso	Foto única (2023)	Nacional únicamente	Diagnóstico × urgencia
Altas_Diagnostico_principal	Foto única (2023)	Nacional únicamente	Diagnóstico × edad
Estancia_media	Foto única (2023)	Nacional únicamente	Diagnóstico × edad
Tablas_CCAA_2023	Foto única (2023)	CCAA	Dotación, personal, actividad - sin desagregar por diagnóstico
Actividad_Evolucion 2014-2023	Anual, 10 años	Nacional	Agregados de actividad (sin diagnóstico)

Fuente	Frecuencia temporal	Nivel geográfico	Nivel clínico
Dotacion_Evolucion 2014-2023	Anual, 10 años	Nacional	Agregados de dotación (sin diagnóstico)

La conclusión que ya orientó el índice se confirma con el detalle real de cada fichero: ninguna fuente cruza simultáneamente diagnóstico + territorio (CCAA/provincia) + tiempo (varios años). El único cruce territorio × diagnóstico disponible es una foto de 2023 (Alta_Diagnostico_Provincia), y el único cruce con años múltiples (Actividad_Evolucion, Dotacion_Evolucion) es a nivel nacional agregado, sin diagnóstico ni territorio. Esto descarta de raíz cualquier forecasting semanal o panel CCAA multianual, y confirma que el índice estructural (foto 2023) y el bloque de tendencia nacional (serie 2014-2023) deben tratarse como dos análisis distintos, no como una sola tabla.

Además, se confirma una limitación adicional no evidente hasta abrir los ficheros: motivo de alta, urgencia del ingreso y estancia media solo existen a nivel nacional, no cruzados con provincia (INE, 2024). Esto significa que el índice de presión asistencial por CCAA/provincia (sección 4) solo podrá construirse con las variables que sí tienen ese cruce territorial -fundamentalmente el volumen de altas por diagnóstico (Alta_Diagnostico_Provincia) y la dotación/personal de Tablas_CCAA_2023 (Ministerio de Sanidad, 2025)- mientras que traslados, fallecimientos, urgencia y estancia media se incorporan como contexto nacional por diagnóstico, no como variable territorial.

2.3 Estructura y exploración de cada fichero

Todos los ficheros comparten un patrón de origen INE: cabecera descriptiva (título, unidades, año), tabla de datos con la primera columna como diagnóstico (codificado según la CIE-10; Organización Mundial de la Salud [OMS], 2019, en formato jerárquico capítulo/subcapítulo) y columnas posteriores como cruces (territorio, sexo, edad, motivo o urgencia según el fichero).

- Alta_Diagnostico_Provincia: una única hoja (tabla-74901), con 63 columnas de territorio (nacional, 17 CCAA y sus provincias, más Ceuta y Melilla) y filas de diagnóstico a dos niveles de detalle (capítulo, p. ej. "0100 CIERTAS ENFERMEDADES INFECCIOSAS...", y subcapítulo, p. ej. "0101 Enfermedades infecciosas intestinales..."). Repite el bloque para "Ambos sexos", "Hombres" y "Mujeres" en la misma hoja.
- Alta_Motivo_ingreso / Alta_Urgencia_ingreso / Altas_Diagnostico_principal / Estancia_media: una hoja cada uno, estructura de diagnóstico en filas y cruce específico en columnas (motivo, urgencia o edad), repetido por sexo. Sin columna de territorio.

- **Tablas_CCAA_2023:** libro con 24 hojas, una por tabla numerada (1.1 a 7.3) más un índice y dos hojas de gráficos. Cada hoja tiene las CCAA en filas y los indicadores de esa tabla en columnas (hospitales, camas, personal, tecnología, actividad diagnóstica). No hay una columna común de diagnóstico que permita cruzar estas tablas con **Alta_Diagnostico_Provincia** a ese nivel; el cruce solo es posible a nivel de CCAA agregada (Ministerio de Sanidad, 2025).
- **Actividad_Evolucion_2014-2023 / Dotacion_Evolucion_2014-2023:** cada uno con un índice y varias hojas ("TABLA 3.1 3.2", "TABLA 1.1 1.2", etc.), con los años 2014-2023 como columnas y los indicadores agregados nacionales en filas (Ministerio de Sanidad, 2025).

2.4 Calidad de los datos

- **Codificación jerárquica de diagnóstico:** cada fichero mezcla en la misma columna el nivel de capítulo (p. ej. "0100 CIERTAS ENFERMEDADES...") y el de subcapítulo (p. ej. "0101 Enfermedades infecciosas intestinales..."), identificable por el prefijo numérico (OMS, 2019). Es necesario decidir en la preparación de datos a qué nivel se trabaja y filtrar el otro para no duplicar el total.
- **Valores de secreto estadístico o no significativos:** como es habitual en tablas del INE con recuentos bajos por celda (INE, 2024), existen combinaciones marcadas como no disponibles (..) que deben tratarse como ausentes, no como cero, para no sesgar el índice a la baja en territorios pequeños (Ceuta, Melilla, provincias con menor población).
- **Hojas con múltiples tablas o cabeceras repetidas:** varias hojas (p. ej. **Tablas_CCAA_2023**; Ministerio de Sanidad, 2025) incluyen el título del libro completo repetido en cada pestaña antes de la tabla real, lo que exige saltar un número variable de filas de cabecera por hoja al parsear.
- **Nombres de territorio no normalizados entre ficheros:** por ejemplo, "Asturias, Principado de" en **Alta_Diagnostico_Provincia** frente a "Asturias, Principado" en **Tablas_CCAA_2023**; será necesario un diccionario de normalización de nombres de CCAA para poder cruzar ambas fuentes de forma fiable.

2.5 EDA de la serie anual nacional 2014-2023

Este apartado analiza la evolución agregada a nivel nacional de la actividad hospitalaria y de la dotación de camas a lo largo de la última década, a partir de los ficheros **Actividad_Evolucion_2014-2023.xlsx** y **Dotacion_Evolucion_2014-2023.xlsx** (Ministerio de Sanidad, 2025). Como se ha indicado en el apartado 2.2, esta serie presenta únicamente desagregación temporal, sin distinción por comunidad autónoma ni por diagnóstico, por lo que su función en el presente trabajo es proporcionar contexto y tendencia, y no constituir la fuente del índice estructural

desarrollado en el apartado 4, que se construye sobre la fotografía transversal del año 2023 (apartado 2.6).

Tabla resumen de la serie 2014 - 2023

Año	Altas totales	Estancia media (días)	Ocupación (%)	Urgencias	Camas públicas	Camas privadas	Camas totales
2014	5.264.867	7,36	77,03	26.973.994	109.435	28.442	137.877
2015	5.285.563	7,36	77,29	28.053.453	110.150	27.814	137.964
2016	5.344.086	7,31	77,61	29.512.722	110.734	27.132	137.866
2017	5.336.131	7,29	76,94	30.030.788	111.598	26.983	138.581
2018	5.390.303	7,27	77,20	30.372.325	112.362	26.699	139.061
2019	5.383.760	7,23	76,84	31.342.724	112.264	26.597	138.861
2020	4.639.007	7,66	69,51	22.907.100	113.660	26.317	139.977
2021	4.942.588	7,46	71,94	27.980.842	114.195	26.202	140.397
2022	5.159.517	7,29	73,30	31.152.076	115.425	25.126	140.551
2023	5.301.878	7,11	73,97	33.375.738	117.482	22.207	139.689

Fuente: elaboración propia a partir de Actividad_Evolucion_2014-2023.xlsx y Dotacion_Evolucion_2014-2023.xlsx (Ministerio de Sanidad, 2025).

Evolución de las altas hospitalarias totales




Figura 2.5.1. Evolución de las altas hospitalarias totales en España (2014-2023). Fuente: elaboración propia a partir de Ministerio de Sanidad (2025).

Como se observa en la Figura 2.5.1, se aprecia un crecimiento sostenido entre 2014 (5.264.867 altas) y 2019 (5.383.760 altas), equivalente a un incremento acumulado del 2,3%. La ruptura asociada a la pandemia de COVID-19 se manifiesta de forma abrupta en 2020, con una caída hasta 4.639.007 altas, un descenso del 13,8% respecto al ejercicio anterior y la mayor variación interanual de toda la serie (Ministerio de Sanidad, 2025). La recuperación posterior, entre 2020 y 2023, es notable en términos relativos (+14,3%), si bien resulta incompleta: el volumen de altas de 2023 (5.301.878) permanece un 1,5% por debajo del máximo alcanzado en 2019.

Estancia media e índice de ocupación




Figura 2.5.2. Evolución de la estancia media y del índice de ocupación hospitalaria en España (2014-2023). Fuente: elaboración propia a partir de Ministerio de Sanidad (2025).

Como muestra la Figura 2.5.2, la estancia media presenta una tendencia decreciente ya con anterioridad a la pandemia, pasando de 7,36 días en 2014 a 7,23 días en 2019, lo que resulta compatible con una mejora progresiva en la eficiencia de la gestión de camas. En 2020 se produce un repunte puntual hasta 7,66 días, el valor máximo de toda la serie, atribuible a la combinación de un menor número de ingresos totales y a estancias más prolongadas asociadas a los casos graves de COVID-19. A partir de 2021 la estancia media retoma la tendencia descendente previa, alcanzando en 2023 su valor mínimo (7,11 días).

El índice de ocupación presenta un comportamiento inverso al que cabría esperar durante el pico de la crisis sanitaria: en lugar de incrementarse, desciende del 76,8% en 2019 al 69,5% en 2020, como consecuencia de la paralización de buena parte de la actividad programada. La recuperación es progresiva pero, al igual que ocurre con las altas totales, el valor de 2023 (74,0%) todavía no alcanza el nivel observado en 2019 (Ministerio de Sanidad, 2025).

Dotación de camas: públicas frente a privadas




Figura 2.5.3. Evolución de las camas hospitalarias en funcionamiento, públicas y privadas, en España (2014-2023). Fuente: elaboración propia a partir de Ministerio de Sanidad (2025).

Según se aprecia en la Figura 2.5.3, el total nacional de camas en funcionamiento se mantiene prácticamente estable durante la década, con una variación acumulada del 1,3% entre 2014 y 2023. Esta estabilidad agregada oculta, sin embargo, una recomposición estructural relevante entre ambos subsectores: las camas públicas del Sistema Nacional de Salud aumentan un 7,3% (de 109.435 a 117.482), mientras que las camas privadas se reducen un 21,9% (de 28.442 a 22.207), con la mayor parte de este descenso concentrada en los dos últimos ejercicios de la serie (Ministerio de Sanidad, 2025). Como resultado, el peso relativo de la dotación pública sobre el total pasa del 79,4% en 2014 al 84,1% en 2023.

Urgencias hospitalarias atendidas




Figura 2.5.4. Evolución de las urgencias hospitalarias atendidas en España (2014-2023). Fuente: elaboración propia a partir de Ministerio de Sanidad (2025).

Tal como refleja la Figura 2.5.4, la evolución de las urgencias hospitalarias atendidas constituye la variable que presenta el crecimiento estructural más pronunciado de las

analizadas en este apartado. Tras la caída registrada en 2020 (-26,9% respecto a 2019, la más acusada de toda la serie), la recuperación no solo alcanza sino que supera de forma clara el nivel prepandemia, alcanzando en 2023 un máximo histórico de 33.375.738 urgencias atendidas, un 6,5% por encima del valor de 2019 (Ministerio de Sanidad, 2025). Este comportamiento contrasta con el de las altas hospitalarias, que a cierre de la serie permanecen por debajo de su nivel prepandemia, y constituye un primer indicio, a nivel nacional, de una presión asistencial creciente que motiva el desarrollo del índice estructural planteado en este trabajo.

En relación con la evolución del volumen nacional de altas hospitalarias y la magnitud de la ruptura de 2020-2021, los datos muestran un crecimiento moderado y sostenido entre 2014 y 2019 (+2,3%), seguido de una caída abrupta en 2020 (-13,8% interanual, la más pronunciada de la serie) y una recuperación incompleta hacia 2023, que se sitúa un 1,5% por debajo del máximo prepandemia. Se trata, por tanto, de un episodio claramente identificable y cuantificable, aunque ya superado en términos de tendencia en el año de referencia empleado para el índice estructural (2023).

En cuanto a si la dotación de camas y de personal ha crecido al mismo ritmo que la actividad, la respuesta que permiten ofrecer las fuentes disponibles es parcial. La dotación de camas se ha mantenido prácticamente estable a lo largo de la década (+1,3% en el total), muy por debajo del crecimiento experimentado por la demanda urgente (+6,5% respecto a 2019, con máximo histórico en 2023), lo que apunta a una brecha creciente entre la presión asistencial urgente y la capacidad instalada. No resulta posible, sin embargo, extender esta conclusión a la dotación de personal, dado que el fichero Dotacion_Evolucion_2014-2023.xlsx no incluye una serie histórica de personal, sino únicamente de camas, quirófanos y dotación tecnológica (Ministerio de Sanidad, 2025). El único dato disponible sobre personal corresponde a la fotografía del año 2023 (Tablas_CCAA_2023.xlsx), que se incorpora como variable estructural del índice desarrollado en el apartado 4, y no como serie temporal.

2.6 EDA de la foto 2023

Este apartado analiza la fotografía transversal del ejercicio 2023, único año en el que las fuentes disponibles permiten cruzar diagnóstico con territorio (Alta_Diagnostico_Provincia.xlsx), así como el motivo de alta (Alta_Motivo_ingreso.xlsx) y la estancia media por grupo de edad (Estancia_media.xlsx) a nivel nacional (INE, 2024). Este bloque constituye la base empírica sobre la que se construirá el índice estructural de presión asistencial desarrollado en el apartado 4.




Figura 2.6.1. Distribución de altas hospitalarias por capítulo diagnóstico a nivel nacional, España 2023. Fuente: elaboración propia a partir de INE (2024).

Como muestra la Figura 2.6.1, sobre un total de 4.866.745 altas hospitalarias registradas en España en 2023 (INE, 2024), tres capítulos diagnósticos concentran conjuntamente algo más de un tercio del volumen total: las enfermedades del aparato digestivo (12,6%), las enfermedades del sistema circulatorio (12,1%) y las enfermedades del sistema respiratorio (11,9%). A continuación se sitúan las lesiones y envenenamientos (9,6%) y las neoplasias (9,4%). Esta concentración en un número reducido de capítulos diagnósticos es coherente con la práctica clínica habitual y constituye el punto de partida para valorar si dicha distribución se mantiene estable entre comunidades autónomas o si, por el contrario, existen patrones territoriales diferenciados.




Figura 2.6.2. Peso de los tres capítulos diagnósticos principales sobre el total de altas, por comunidad autónoma, España 2023. Fuente: elaboración propia a partir de INE (2024).

Como se aprecia en la Figura 2.6.2, al comparar el peso relativo de estos tres capítulos diagnósticos entre comunidades autónomas, se aprecia que, si bien el aparato digestivo es el capítulo predominante en la mayoría de los territorios, existen excepciones relevantes. En Asturias, Cantabria, Canarias, Cataluña y Extremadura, el sistema circulatorio desplaza al aparato digestivo como principal motivo de alta, alcanzando en Asturias un peso del 15,3% sobre el total de altas de la comunidad, el valor más alto observado para cualquier capítulo en cualquier territorio. En Madrid, por su parte, es el sistema respiratorio el que ocupa la primera posición (12,8%). En el extremo opuesto, Castilla-La Mancha (14,7%) y Castilla y León (14,6%) presentan la mayor concentración relativa en el aparato digestivo. Esta heterogeneidad confirma que el territorio aporta información relevante más allá de la distribución nacional agregada, lo que justifica metodológicamente la construcción de un índice de presión asistencial desagregado por comunidad autónoma en lugar de limitarse a un ranking nacional de patologías.




Figura 2.6.3. Tasas de traslado a otro centro y de fallecimiento por capítulo diagnóstico, España 2023. Fuente: elaboración propia a partir de INE (2024).

Como recoge la Figura 2.6.3, a nivel nacional, el 5,8% de las altas hospitalarias de 2023 tuvieron como motivo el traslado a otro centro y el 4,5% correspondieron a fallecimiento (INE, 2024). Estas tasas globales, sin embargo, ocultan diferencias sustanciales entre capítulos diagnósticos. La tasa de traslado más elevada corresponde a los trastornos mentales, con un 13,3% de las altas de ese capítulo derivando en traslado a otro centro, más del doble de la tasa global y muy por encima del segundo capítulo, enfermedades del sistema circulatorio (9,4%). En cuanto a la tasa de fallecimiento, el valor más alto se registra en ciertas enfermedades infecciosas y parasitarias (13,1%), seguido de las neoplasias (8,8%) y las enfermedades del sistema circulatorio (6,9%). Como se ha señalado en el apartado 2.2, estas tasas solo están disponibles a nivel nacional, por lo que no es posible, con las fuentes actuales, determinar si estas diferencias por diagnóstico se mantienen de forma homogénea entre comunidades autónomas o si existen, además, diferencias territoriales superpuestas.




Figura 2.6.4. Estancia media por grupo de edad y capítulo diagnóstico, España 2023 (excluye Trastornos mentales, en escala aparte). Fuente: elaboración propia a partir de INE (2024).

Según se observa en la Figura 2.6.4, la relación entre estancia media y grupo de edad presenta, para la mayoría de los capítulos diagnósticos analizados, un patrón en forma de U: valores relativamente altos en los grupos de menor edad (particularmente en menores de 1 año), un descenso hasta un mínimo situado entre los 15 y los 34 años, y un incremento progresivo y sostenido a partir de esa franja hasta los grupos de mayor edad. Así, la estancia media para el conjunto de diagnósticos pasa de 8,10 días en menores de 1 año a un mínimo de 3,75 días en el grupo de 5 a 14 años, para volver a superar los 9 días a partir de los 65 años y alcanzar 10,78 días en el grupo de 90 a 94 años (INE, 2024). Este patrón se repite, con matices, en capítulos como el aparato digestivo o el sistema respiratorio.



Figura 2.6.5. Estancia media por grupo de edad, capítulo de trastornos mentales, España 2023.
Fuente: elaboración propia a partir de INE (2024).

Como ilustra la Figura 2.6.5, el capítulo de trastornos mentales constituye una excepción de magnitud muy superior al resto y se presenta en un gráfico independiente por la diferencia de escala. Frente a estancias medias de un solo dígito en el resto de capítulos, los trastornos mentales alcanzan 54,3 días de estancia media en menores de 1 año, descienden a valores mínimos en la infancia y adolescencia (en torno a 3 días entre 1 y 14 años) y aumentan de forma muy pronunciada a partir de la madurez, hasta superar los 100 días de estancia media en los grupos de 75 a 94 años, con un máximo de 113,7 días en el grupo de 85 a 89 años (INE, 2024). Esta magnitud, entre diez y quince veces superior a la del resto de capítulos diagnósticos en los grupos de mayor edad, resulta coherente con la naturaleza de los ingresos psiquiátricos de larga estancia en población mayor y constituye uno de los hallazgos más relevantes de este bloque de EDA, si bien su interpretación clínica excede el alcance analítico de este trabajo.

En relación con las preguntas de negocio planteadas para este bloque, el análisis confirma que, aunque el aparato digestivo, el sistema circulatorio y el sistema respiratorio son sistemáticamente los tres capítulos de mayor peso en todo el territorio nacional, el orden entre ellos varía de forma sistemática por comunidad autónoma,

con el sistema circulatorio como diagnóstico principal en cinco comunidades y el sistema respiratorio como principal en Madrid, lo que justifica empíricamente construir el índice de presión asistencial a nivel de comunidad autónoma y no únicamente a nivel nacional. En cuanto a qué patologías presentan mayor tasa de traslado o fallecimiento, los trastornos mentales destacan de forma clara en traslados (13,3% frente a una media nacional del 5,8%) y las enfermedades infecciosas y parasitarias encabezan la tasa de fallecimiento (13,1% frente a una media nacional del 4,5%), si bien esta respuesta queda limitada al ámbito nacional por la ausencia de desagregación territorial en la fuente correspondiente. Por último, respecto a la relación entre estancia media y grupo de edad por diagnóstico, se confirma un patrón general en forma de U en la mayoría de los capítulos, con mínimos en edades jóvenes y máximos en los grupos de mayor edad, y se identifica en los trastornos mentales una excepción de magnitud muy superior al resto de diagnósticos, con estancias medias que superan los 100 días en los grupos de mayor edad.

2.7 Conclusión de la fase

La validación fichero a fichero confirma y precisa lo ya anticipado en el índice: el proyecto puede sostener con datos 100% reales un índice estructural de presión asistencial por diagnóstico y CCAA/provincia para el año 2023 (construido principalmente sobre Alta_Diagnostico_Provincia cruzado con la dotación de Tablas_CCAA_2023; INE, 2024; Ministerio de Sanidad, 2025), y un bloque descriptivo de tendencia nacional 2014-2023 (sobre Actividad_Evolucion y Dotacion_Evolucion; Ministerio de Sanidad, 2025), tratados como dos análisis separados y no combinables entre sí a nivel de detalle.

Quedan explícitamente descartados por falta de granularidad real en las fuentes:

- Cualquier forecasting semanal (ninguna fuente tiene frecuencia inferior a la anual).
- Un panel CCAA × varios años (las series históricas disponibles son solo nacionales).
- Cruce de motivo de alta, urgencia o estancia media con territorio (esas tres variables solo existen a nivel nacional).
- Reingreso a 30 días por paciente (ninguna de las ocho fuentes contiene un identificador de episodio o paciente; ver Anexo C).

3. Preparación de los datos (Data Preparation)

Esta fase construye la capa gold sobre la que se apoyará el modelado de la sección 4: el índice estructural de presión asistencial por patología y comunidad autónoma, año 2023. Todo el proceso descrito a continuación está implementado en el script `tfm_pipeline_seccion3.py` (y en su versión notebook para Google Colab), desarrollado en Python con la librería pandas (McKinney, 2010) y ejecutado de principio a fin sin errores sobre los 8 ficheros originales.

3.1 Selección de tablas y campos finales por dataset

De las 8 fuentes validadas en la fase de Data Understanding (sección 2), la capa gold del índice estructural utiliza cinco:

Fichero	Qué aporta	Nivel	Papel en la capa gold
Alta_Diagnostico_Provincia.xlsx (INE, 2024)	Altas hospitalarias por capítulo CIE-10 × comunidad autónoma	CCAA/provincia, foto 2023	Variable base del índice - único cruce diagnóstico × territorio disponible
Tablas_CCAA_2023.xlsx (tablas 1.1, 2.1, 4.1, 5.1, 5.2 y 6.4; Ministerio de Sanidad, 2025)	Hospitales, dotación de camas, personal, frecuentación, indicadores de hospitalización y urgencias	CCAA, foto 2023	Contexto estructural territorial
Alta_Motivo_ingreso.xlsx (INE, 2024)	Traslado a otro centro y fallecimiento por diagnóstico	Nacional	Contexto nacional por patología
Alta_Urgencia_ingreso.xlsx (INE, 2024)	% de ingreso urgente por diagnóstico	Nacional	Contexto nacional por patología
Estancia_media.xlsx (INE, 2024)	Estancia media por diagnóstico	Nacional	Contexto nacional por patología

`Actividad_Evolucion_2014-2023.xlsx` y `Dotacion_Evolucion_2014-2023.xlsx` (Ministerio de Sanidad, 2025) quedan fuera de esta capa: alimentan el bloque de tendencia nacional, ya trabajado en el EDA de la sección 2, y no son combinables con el corte transversal de 2023 sin perder el detalle territorial o de diagnóstico.

Dentro de `Alta_Diagnostico_Provincia`, `Alta_Motivo_ingreso`, `Alta_Urgencia_ingreso` y `Estancia_media`, se seleccionan exclusivamente las filas de nivel capítulo CIE-10 (OMS, 2019) -código de 4 dígitos terminado en 00 (p. ej. 1100 = enfermedades del aparato digestivo), excluyendo tanto el total general (0000) como los subcapítulos (p. ej. 1101). Esto da como resultado 20 capítulos diagnósticos, coherentes con los ya utilizados en el EDA de la sección 2.

3.2 Limpieza: tipado, valores ".." y nulos, normalización de nombres de CCAA/provincia, snake_case

Los problemas de calidad identificados en la sección 2 se resuelven de la siguiente manera:

- **Cabeceras multinivel y hojas con título repetido.** Cada hoja de Tablas_CCAA_2023.xlsx requiere saltar un número distinto de filas antes de llegar a la tabla real (desde la fila 3 en la tabla 1.1 hasta la fila 7 en la 5.1). Se resuelve localizando dinámicamente la fila de cabecera de cada hoja en lugar de asumir un desplazamiento fijo.
- **Nombres de territorio no normalizados entre ficheros.** Alta_Diagnostico_Provincia usa nombres en mayúsculas ("ASTURIAS, PRINCIPADO DE"), mientras que Tablas_CCAA_2023 los da en formato mixto ("Asturias, Principado de"). Se implementa normalize_ccaa(), que pasa a minúsculas, elimina tildes, comas y la letra ñ (sustituida por n - sin este paso, País Vasco y Cataluña no casaban con el diccionario canónico) y hace match por prefijo contra una lista de 18 territorios canónicos.
- **Ceuta y Melilla.** En Alta_Diagnostico_Provincia son dos columnas independientes; en Tablas_CCAA_2023 aparecen ya combinadas en una sola fila ("Ceuta y Melilla"). Para poder integrar ambas fuentes sin perder esa información, se agregan las dos ciudades autónomas en una única unidad territorial en todo el dataset. Es una decisión de diseño explícita, no una pérdida de granularidad oculta.
- **Valores de secreto estadístico (..).** Se tratan como ausentes, nunca como cero (INE, 2024), para no sesgar a la baja el índice en los territorios de menor tamaño. En la práctica, ninguna de las columnas finalmente seleccionadas para la capa gold contiene celdas de este tipo tras la selección de capítulos y CCAA (ver validación de nulos en el punto 3.6).
- **snake_case.** Todos los campos de la capa gold se nombran en snake_case (camas_funcionamiento_por1000, pct_fallecimiento_nacional, etc.).

3.3 Integración: cruce de Alta_Diagnostico_Provincia con Tablas_CCAA_2023 a nivel de CCAA

La integración combina, para cada una de las 18 unidades territoriales (17 CCAA + Ceuta y Melilla), los volúmenes de altas de los 20 capítulos diagnósticos (INE, 2024) con seis tablas de contexto estructural extraídas de Tablas_CCAA_2023.xlsx (Ministerio de Sanidad, 2025):

Tabla origen	Variables incorporadas
1.1 Hospitales según dependencia	hospitales_sns, hospitales_privados, hospitales_total
2.1 Dotación de camas	camas_instaladas_total, camas_funcionamiento_total, camas_funcionamiento_por1000, pct_camias_sns
4.1 Personal según vinculación	personal_vinculado, personal_por1000
5.1 Frecuentación	ingresos_total_ccaa, altas_total_ccaa, altas_por1000, estancias_por1000
5.2 Indicadores de hospitalización	estancia_media_sns, ocupacion_sns, rotacion_sns, mortalidad_sns (y sus equivalentes del subsector privado)
6.4 Actividad de urgencias	urgencias_total, urgencias_por1000, presion_urgencias

Para las variables de la tabla 5.2 se utilizan los indicadores del subsector público-SNS como valor representativo de cada CCAA: la dotación pública concentra entre el 69,8% y el 100% de las camas en funcionamiento según el territorio (con una media cercana al 84%, ya documentada en el EDA de tendencia nacional de la sección 2), por lo que resulta la referencia más estable para comparar territorios; el subsector privado queda igualmente disponible en la capa gold como variable adicional, no como sustituto.

El resultado de la integración es una tabla de 360 filas (20 patologías × 18 territorios) sin ningún valor nulo, con clave (ccaa, patología).

Como primer control de coherencia del cruce, la correlación entre `camas_funcionamiento_por1000` y `altas_por1000` a nivel de CCAA es de 0,72: los territorios con más camas por habitante tienden a registrar también más altas por habitante, un resultado esperable que respalda la calidad de la integración y, a la vez, anticipa uno de los riesgos que deberá controlar el modelado (distinguir dotación de demanda real).

3.4 Variables derivadas

A partir de las tres fuentes nacionales por patología se calculan cuatro tasas, y a partir del cruce diagnóstico × CCAA, dos ratios de presión:

Variable	Cálculo	Ejemplo (rango observado)
<code>tasa_traslado_nacional</code>	traslados a otro centro / altas totales, por patología	Máximo en trastornos mentales (13,3%); mínimo en complicaciones del embarazo, parto y puerperio (1,0%)
<code>pct_fallecimiento_nacional</code>	fallecimientos / altas totales, por patología	Máximo en ciertas enfermedades infecciosas y parasitarias (13,1%, ver sección 2); mínimo en complicaciones del embarazo (0,004%)
<code>pct_urgente_nacional</code>	ingresos urgentes / ingresos totales, por patología	Entre el 43,7% (enfermedades del ojo) y el 80,6% (complicaciones del embarazo)
<code>estancia_media_dias_nacional</code>	estancia media en días, por patología	Desde 3,0 días (enfermedades del oído) hasta 54,3 días (trastornos mentales, ya analizado en el EDA de la sección 2)
<code>altas_pct_sobre_ccaa</code>	altas de la patología / altas totales de esa CCAA	Para aparato digestivo, entre el 11,4% (Cantabria/Cataluña) y el 14,7% (Castilla-La Mancha)
<code>altas_por1000hab_camras</code>	altas de la patología / camas en funcionamiento de la CCAA	Proxy de presión estructural sobre la dotación instalada

Los ratios de dotación por 1.000 y 100.000 habitantes (`camas_funcionamiento_por1000`, `personal_por1000`, `urgencias_por1000`, etc.) no se recalculan: ya vienen normalizados por población en origen en `Tablas_CCAA_2023.xlsx` (Ministerio de Sanidad, 2025), y se incorporan directamente

para evitar introducir un denominador poblacional propio que no coincidiría exactamente con el usado por el INE/Ministerio de Sanidad.

Como primera lectura de la variable de presión agregada (altas totales de la CCAA / camas en funcionamiento), el territorio con mayor ratio es la Comunitat Valenciana (45,3 altas por cama), y el de menor, Canarias (27,0); es decir, la CCAA más presionada estructuralmente casi duplica ($\times 1,68$) a la menos presionada - la variabilidad territorial que justifica, ya en esta fase, la construcción de un índice desagregado por CCAA en la sección 4.

3.5 Limitación documentada: Alta_Motivo_ingreso (traslados/fallecimiento) solo a nivel nacional

Se deja constancia expresa de una limitación real de fuente, ya anticipada en la sección 2: `tasa_traslado_nacional`, `pct_fallecimiento_nacional`, `pct_urgente_nacional` y `estancia_media_dias_nacional` toman el mismo valor en las 18 unidades territoriales para una misma patología, porque ninguna de sus tres fuentes (`Alta_Motivo_ingreso`, `Alta_Urgencia_ingreso`, `Estancia_media`; INE, 2024) desagrega por CCAA o provincia.

Esto se ha verificado de forma automática en el pipeline: para trastornos mentales (código 0500), la variable `tasa_traslado_nacional` toma el valor 0,1326 en las 18 filas correspondientes a las 18 CCAA, sin ninguna variación. No se ha interpolado, repartido ni sintetizado ningún valor territorial para estas cuatro variables. Se incorporan a la capa gold marcadas con el sufijo `_nacional` precisamente para que, en el modelado y en el dashboard, no se lean por error como una diferencia real entre comunidades autónomas, sino como contexto de patología aplicado por igual a todo el territorio.

3.6 Capa gold final: datasets, diccionario de datos y claves primarias

El pipeline genera tres ficheros:

- `gold_presion_asistencial_2023.csv` - clave primaria (`anio`, `ccaa`, `patologia_cie10`). 360 filas, 45 columnas, 0 valores nulos. Es la tabla que alimentará el modelado de la sección 4.
- `gold_contexto_ccaa_2023.csv` - clave primaria (`ccaa`). 18 filas, 34 columnas, 0 nulos. Contexto estructural completo por territorio, reutilizable fuera del cruce por patología (por ejemplo, para el dashboard de la sección 6).
- `diccionario_datos_gold_2023.csv` - diccionario de datos generado automáticamente a partir del propio dataframe (campo, tipo, nulos, valor de ejemplo), con las 45 columnas de la capa principal documentadas.

Como control de calidad final, la suma de altas de la capa gold (4.861.330) se compara con la cifra oficial nacional de 2023 (4.866.745, citada en el EDA de la sección 2; INE, 2024): la diferencia es de 0,11%, atribuible a residuos de secreto estadístico en combinaciones de muy bajo volumen entre capítulo diagnóstico y territorio pequeño, y se considera despreciable para los fines del índice.

3.7 Qué se descarta y por qué

Elemento descartado	Motivo
Subcapítulos CIE-10 (códigos no terminados en 00)	Se trabaja a nivel de capítulo para no duplicar el total al agregar, y por coherencia con el nivel de detalle disponible en el resto de fuentes
Años 2020-2021 en el bloque de tendencia nacional	Ruptura estructural pandémica, ya tratada y justificada en el EDA de la sección 2
Cruce de traslado/fallecimiento/urgencia/estancia media con CCAA o provincia	No existe en ninguna de las 8 fuentes públicas disponibles; se documenta como hueco real (punto 3.5), no se estima ni se sintetiza
Provincias (nivel inferior a CCAA en Alta_Diagnostico_Provincia)	El resto de fuentes de contexto estructural (Tablas_CCAA_2023) no baja de nivel CCAA; descender a provincia rompería la integración y generaría combinaciones de muy bajo volumen
Sexo como variable de cruce	Se usa el bloque "Ambos sexos" para mantener el foco en el índice territorial; queda documentado como línea futura de desagregación (Anexo)

3.8 Validación visual de la capa gold




Figura 3.1. Presión estructural agregada por comunidad autónoma (altas totales 2023 / camas en funcionamiento), a partir de la capa gold gold_presion_asistencial_2023.csv agregada por territorio. Fuente: elaboración propia a partir de INE (2024) y Ministerio de Sanidad (2025).

Como control final de la integración -y primer avance del tipo de lectura que permitirá el índice de la sección 4-, la Figura 3.1 agrega las 360 filas de la capa gold por CCAA y confirma la variabilidad territorial ya apuntada en el punto 3.4: la Comunitat Valenciana (45,3 altas por cama), Madrid (40,7) y Balears (39,5) encabezan la presión

estructural agregada, frente a Canarias (27,0), Ceuta y Melilla (29,1) y Extremadura (29,7) en el extremo opuesto - un ratio máximo sobre mínimo de 1,68. Al tratarse de una agregación directa de la capa gold (y no de un cálculo independiente), esta figura sirve también como verificación de que la integración diagnóstico × CCAA × contexto estructural se ha realizado correctamente para las 18 unidades territoriales.

Nota metodológica de cierre: la capa gold construida en esta sección sostiene, con datos 100% reales, un índice de presión asistencial a nivel patología × CCAA para 2023, con un bloque de contexto nacional por patología claramente diferenciado y marcado como tal. Ninguna variable ha sido estimada, interpolada o sintetizada para completar cruces que las fuentes públicas no ofrecen - la ausencia de esos cruces se documenta como resultado, no se disimula.

4. Modelado (Modeling)

4.1 Planteamiento del índice: variable objetivo, predictoras, y por qué es un modelo de corte transversal

Variable objetivo: `altas_por1000hab_camas` - altas de una patología en una CCAA entre las camas en funcionamiento de esa CCAA. Es la misma variable ya usada como validación visual de la capa gold (Figura 3.1): el índice no parte de una etiqueta inventada, sino de un proxy real y directamente calculable a partir de la capa gold, lo que permite que el "índice de presión asistencial" final sea el resultado de un modelo entrenado sobre esa magnitud, con pesos aprendidos y justificables, no una fórmula de pesos fijados a criterio propio.

Predictoras, agrupadas en dos niveles (12 variables):

Nivel	Variables	Varía por
Patología (nacional)	<code>tasa_traslado_nacional</code> , <code>pct_fallecimiento_nacional</code> , <code>pct_urgente_nacional</code> , <code>estancia_media_dias_nacional</code>	Solo por patología (constante en las 18 CCAA, ver limitación documentada en 3.5)
CCAA (contexto estructural)	<code>personal_por1000</code> , <code>ocupacion_sns</code> , <code>rotacion_sns</code> , <code>mortalidad_sns</code> , <code>urgencias_por1000</code> , <code>presion_urgencias</code>	Solo por CCAA (constante en las 20 patologías)

Se excluye explícitamente `altas_pct_sobre_ccaa` como predictora, pese a que varía a nivel de segmento (patología × CCAA) y podría parecer la más informativa: comparte el numerador altas con la variable objetivo ($\text{altas_pct_sobre_ccaa} = \text{altas} / \text{altas_total_ccaa}$ frente a $\text{altas_por1000hab_camas} = \text{altas} / \text{camas_funcionamiento_total}$). Aunque los denominadores difieren, ambas magnitudes están mecánicamente ligadas al mismo volumen real de altas - incluirla habría sido una fuga de información parcial (Kaufman et al., 2012) disfrazada de predictora estructural, no una variable independiente.

Por qué un modelo de corte transversal, no una serie temporal: el cruce diagnóstico × territorio solo existe como foto única de 2023 (sección 2, "Validación de granularidad real"); ninguna fuente pública lo ofrece en varios años.

Aviso metodológico para la validación (desarrollado en 5.1): las 360 filas de la capa gold no son 360 observaciones independientes. Las 4 variables de patología se repiten en las 18 CCAA (pseudorréplica por patología) y las 8 variables de CCAA se repiten en las 20 patologías (pseudorréplica por CCAA; Hurlbert, 1984); el único componente verdaderamente específico de cada celda es altas (y, por construcción, la variable objetivo). Esto no invalida el modelo, pero obliga a que la validación cruzada de la sección 5 no sea un KFold aleatorio simple -que filtraría información de una misma patología o CCAA entre entrenamiento y test (Roberts et al., 2017)-, sino que se complemente con GroupKFold por patología y GroupKFold por CCAA.

4.2 Alternativas de modelo y regla de decisión

Los modelos se implementan con la librería scikit-learn (Pedregosa et al., 2011).

Alternativa	Por qué se plantea	Limitación / riesgo a controlar
Regresión Ridge (candidato principal; Hoerl y Kennard, 1970)	Coeficientes directamente interpretables como el peso de cada predictora en el índice; la regularización L2 controla la colinealidad esperable entre las variables de patología (que covarían entre sí: mayor pct_fallecimiento_nacional tiende a coincidir con mayor estancia_media_dias_nacional; Hastie et al., 2009)	Asume relación lineal entre predictoras y objetivo; a validar en el EDA de esta fase antes de descartar interacciones
Gradient Boosting Regressor (alternativa de contraste; Friedman, 2001)	Permite capturar interacciones no lineales (p. ej., que la severidad importe más en CCAA con menor dotación de personal) y se usaría junto con SHAP (Lundberg y Lee, 2017) para mantener la explicabilidad por segmento	Con 360 filas y una estructura de datos con bloques repetidos (ver más abajo), el riesgo de sobreajuste es mayor que en Ridge; se acepta solo si mejora de forma clara la capacidad explicativa en la validación cruzada de la sección 5

Regla de decisión: se prioriza Ridge como modelo salvo que Gradient Boosting aporte una mejora sustancial y verificable. Los resultados de la sección 5 muestran que Ridge empeora sustancialmente el baseline en los tres esquemas de validación (relación no lineal), mientras que GBR lo mejora - aunque, como se detalla en 5.2/5.3, esa mejora depende críticamente de qué esquema de validación se use, y es mucho más modesta de lo que sugiere la validación más simple.

4.3 Bloque de tendencia nacional 2014-2023

Con 10 observaciones anuales agregadas a nivel nacional (sin diagnóstico ni CCAA; Ministerio de Sanidad, 2025), este bloque se mantiene explícitamente descriptivo, no predictivo:

- **Se puede decir:** la magnitud y el sentido de la ruptura 2020-2021, la tasa de crecimiento acumulado pre-pandemia (2014-2019, +2,3%) y post-pandemia (2020-2023, +14,3% relativo pero incompleto), el desacoplamiento entre el crecimiento de las urgencias (+6,5% sobre 2019, máximo histórico) y la práctica estabilidad de la dotación de camas (+1,3% en la década), y la recomposición del peso público/privado en la dotación - ver Figuras 2.5.1 a 2.5.4.
- **No se puede decir con garantías:** una proyección de valores futuros. Diez puntos anuales no ofrecen la resolución necesaria para ajustar un modelo de series temporales con validez estadística (ni para descomponer estacionalidad -no existe, es una serie anual-, ni para un intervalo de predicción fiable a 1-2 años vista). Ajustar una regresión lineal simple sobre 10 puntos y proyectarla sería técnicamente posible pero metodológicamente débil: el intervalo de confianza sería artificialmente estrecho y no reflejaría la incertidumbre real de

extrapolar una tendencia de una década con un único punto de ruptura conocido (la pandemia) y, potencialmente, otros no observados. Este bloque aporta contexto de tendencia, no proyección, y no compite con el índice de 4.1 ni pretende sustituirlo.

4.4 Variables descartadas y motivo

Variable / elemento descartado	Motivo
camas_funcionamiento_por1000, altas_por1000 como predictoras	Circularidad: ambas están estructuralmente ligadas al numerador/denominador de la variable objetivo (altas_por1000hab_camas); incluirlas inflaría artificialmente la capacidad explicativa del modelo sin aportar información nueva (Kaufman et al., 2012)
Provincia como nivel de agregación del modelo	Ninguna fuente de contexto estructural (Tablas_CCAA_2023) baja de nivel CCAA; modelar a provincia rompería la integración ya documentada en la sección 3
Sexo como variable del modelo	Se mantiene fuera del índice principal por la misma razón documentada en la preparación de datos (sección 3.7); queda como línea futura de desagregación
Cualquier forecasting a nivel de segmento (patología × CCAA × año)	No existe panel multianual con esa granularidad (ver sección 2.2); descartado de raíz, no simplificado con supuestos
Score de reingreso o de derivación multianual como parte de este modelo	Dependían de fuentes no disponibles a esta granularidad (iCMBD para reingreso, ocupación diaria para derivación); quedan en el Anexo C como diseño conceptual no implementado

4.5 Explicabilidad: importancia de variables y factores principales por segmento

Para el modelo Ridge, cada predictora estandarizada aporta un coeficiente que representa su peso relativo en el índice (Hastie et al., 2009); al ser un modelo lineal, la contribución de cada variable al valor concreto de un segmento (patología × CCAA) se descompone de forma exacta como el producto coeficiente × valor estandarizado de la variable en ese segmento -no hace falta un método de aproximación tipo SHAP para obtenerla, aunque el resultado se comunique en el dashboard con el mismo formato de "factores principales" ya usado en el diseño de frontal de entregas anteriores-.




Figura 4.1: modelado índice de presión. Fuente: elaboración propia.

Si el Gradient Boosting Regressor se valida como alternativa preferible en la sección 5, la explicabilidad pasa a apoyarse en SHAP (Lundberg y Lee, 2017; Lundberg et al.,

2020), que en modelos de árboles no ofrece una descomposición exacta pero sí una atribución consistente y comparable entre segmentos.

En ambos casos, el resultado que llega al dashboard por segmento es el mismo formato: el score reescalado de 0 a 100 y sus 2-3 factores de mayor contribución, expresados en lenguaje no técnico (p. ej. "estancia media muy por encima de la mediana nacional" en lugar de "coeficiente de estancia_media_dias_nacional = 0,34").

5. Evaluación (Evaluation)

5.1 Estrategia de validación: por qué un K-Fold aleatorio simple no basta

Se ejecutan tres esquemas de validación cruzada (5 particiones cada uno), no uno solo, porque responden a preguntas distintas y el aviso metodológico de 4.1 obliga a no quedarse con el más optimista. La validación cruzada estándar asume observaciones independientes; cuando los datos presentan estructura jerárquica o de grupos, debe realizarse por bloques para evitar estimaciones sesgadas de la capacidad predictiva (Roberts et al., 2017):

1. **K-Fold aleatorio simple** - referencia inicial; sobreestima el rendimiento porque, dentro de un mismo fold, filas de la misma patología o la misma CCAA aparecen simultáneamente en entrenamiento y test (Kaufman et al., 2012; Roberts et al., 2017).
2. **GroupKFold por patología** - deja patologías completas fuera; mide si el modelo generaliza a patologías nunca vistas.
3. **GroupKFold por CCAA** - deja comunidades autónomas completas fuera; mide si el contexto estructural territorial generaliza a territorios nunca vistos. Es la validación que responde directamente a la pregunta central del proyecto: ¿el territorio aporta información relevante?

No se usa split temporal: es un corte transversal sin dimensión temporal en el cruce patología × CCAA (sección 4.1). Los esquemas de validación se han implementado con scikit-learn (Pedregosa et al., 2011).

5.2 Métricas y baseline

Baseline: para cada fold y cada esquema, se calcula la media de `altas_por1000hab_camas` de cada patología usando solo las filas de entrenamiento de ese fold, y se usa esa media como predicción -"la media histórica por patología, sin distinguir CCAA" que pide el criterio de éxito del proyecto.

Resultados de los tres esquemas de validación cruzada (MAE medio, 5 particiones):

Esquema	Baseline MAE	GBR MAE	Mejora GBR	Ridge MAE	Mejora Ridge
K-Fold simple	0,2659	0,2431	+8,6%	1,1655	-338%
GroupKFold por patología	1,3532	1,2807	+5,4% (R ² negativo en ambos)	2,2589	-67%
GroupKFold por CCAA	0,2801	0,2782	+0,7%	1,1136	-298%

5.3 Criterio de aceptación -lectura honesta de los tres esquemas

Esta es la corrección metodológica central de la evaluación: el K-Fold simple sobreestima la contribución del territorio (+8,6%) porque filtra información de la misma CCAA entre entrenamiento y test (Roberts et al., 2017). Cuando se fuerza al modelo a generalizar a territorios nunca vistos (GroupKFold por CCAA, la validación que realmente responde a la pregunta del proyecto), la mejora de GBR sobre el baseline cae a +0,7% - prácticamente indistinguible del baseline.

El criterio de éxito del proyecto exige que el modelo mejore sobre el baseline demostrando que el territorio aporta información relevante, sin fijar un umbral numérico estricto. Bajo la validación correcta, esa mejora es real pero marginal (+0,7%), muy por debajo de lo que sugería el K-Fold simple. Ridge, en los tres esquemas, empeora sustancialmente el baseline. Se acepta el modelo con esta salvedad explícita: el hallazgo honesto -no la cifra optimista inicial del K-Fold simple- pasa a ser el resultado central de la revisión crítica (5.4). Si ninguno de los tres esquemas hubiera mostrado mejora alguna, el resultado documentado habría sido el panel descriptivo de la Figura 3.1, sin componente predictivo añadido.

5.4 Revisión crítica: ¿el índice sostiene una conclusión real, o solo confirma patrones ya conocidos?

Con los tres esquemas de validación en la mano, la respuesta se matiza respecto a una primera lectura optimista:

- **La dominancia del perfil clínico de la patología** (trastornos mentales con mayor estancia y traslado, ya documentado en el EDA de la sección 2, Figura 2.6.5) es el hallazgo más sólido, y a la vez el más limitado: el baseline por patología explica un R^2 de 0,90-0,91 con K-Fold simple, pero se desploma a R^2 negativo cuando se generaliza a patologías nunca vistas (GroupKFold por patología). Es decir, el "conocimiento" del modelo sobre una patología depende de haberla visto en alguna CCAA durante el entrenamiento, no de un patrón transferible a partir de sus 4 variables clínicas nacionales.
- **La contribución territorial**, que en el K-Fold simple parecía real (+8,6%, con `personal_por1000` y `rotacion_sns` como factores dominantes), se reduce a +0,7% bajo GroupKFold por CCAA. La conclusión honesta es que, con los datos y la granularidad disponibles, no hay evidencia sólida de que el contexto estructural de una CCAA permita predecir su presión asistencial en territorios no vistos. El índice conserva su utilidad como panel descriptivo y de ranking entre las 18 CCAA y 20 patologías ya conocidas (Figura 3.1), pero no debe presentarse como un modelo predictivo con capacidad de generalización territorial demostrada.
- Esta es exactamente la revisión crítica que exige el propio criterio de éxito del proyecto: el índice separa patologías de forma clara y consistente, pero no separa territorios con evidencia robusta una vez corregido el sesgo de

validación -un resultado más modesto, y más honesto, que la primera estimación con K-Fold simple.

5.5 Riesgos y alternativas

Riesgo	Descripción	Tratamiento
Sobreestimación por fuga entre folds	Un K-Fold aleatorio simple filtra información de la misma patología/CCAA entre entrenamiento y test (Kaufman et al., 2012)	Corregido con GroupKFold por patología y por CCAA (5.1-5.3; Roberts et al., 2017)
Falta de generalización a patologías nuevas	R ² negativo en GroupKFold por patología, tanto para el baseline como para GBR	Se documenta como limitación; el índice se usa como ranking de las patologías ya conocidas, no como clasificador de patologías nuevas
Falta de generalización a territorios nuevos	Mejora de GBR casi nula (+0,7%) en GroupKFold por CCAA	Se documenta como limitación central del proyecto; no se presenta el índice como modelo predictivo territorial validado
Confusión entre severidad clínica y capacidad de red	Un personal_por1000 bajo podría reflejar tanto menor dotación real como una casuística distinta	El modelo no distingue causalidad, solo asociación - límite de interpretación explícito, no resuelto con los datos disponibles
Bajo volumen en combinaciones poco frecuentes	Celdas pequeñas (Ceuta y Melilla, Rioja) con recuentos bajos de altas pueden inflar la varianza de la variable objetivo	Visible en la desviación estándar del MAE entre folds; no se corrige artificialmente

5.6 Explicabilidad: SHAP, score 0-100 y factores principales por segmento

Se usa SHAP (TreeExplainer; Lundberg y Lee, 2017; Lundberg et al., 2020) sobre el modelo GBR final (entrenado sobre el 100% de los datos, una vez fijada la elección de modelo): en modelos de árboles no ofrece una descomposición exacta como en Ridge (coeficiente × valor estandarizado), pero sí una atribución consistente y comparable entre segmentos.

Importancia media |SHAP| (global, mayor a menor):

Variable	Importancia SHAP
pct_fallecimiento_nacional	0,7347
tasa_traslado_nacional	0,3352
pct_urgente_nacional	0,2079
estancia_media_dias_nacional	0,1993
rotacion_sns	0,0793
personal_por1000	0,0563
mortalidad_sns	0,0442
ocupacion_sns	0,0423
pct_camassns	0,0180
presion_urgencias	0,0104
estancia_media_sns	0,0100

Variable	Importancia SHAP
pct_urgencias_ingresadas	0,0077

Para el dashboard de la sección 6, cada segmento (patología × CCAA) recibe un score reescalado de 0 a 100 y sus 2 factores principales (mayor |SHAP| en esa fila), en lenguaje no técnico. Ejemplo real de los extremos del índice:

- **Top:** Comunitat Valenciana + enfermedades del sistema circulatorio → score 100,0 (factores: pct_fallecimiento_nacional, personal_por1000).
- **Bottom:** Ceuta y Melilla + anomalías congénitas → score 0,0 (factores: tasa_traslado_nacional, pct_fallecimiento_nacional).

Lectura, con la misma honestidad que 5.4: las 4 variables de perfil clínico nacional concentran la mayor parte de la importancia SHAP; dentro de las estructurales, rotacion_sns y personal_por1000 son las que más pesan, coherentes con el 5,4%-8,6% de contribución territorial visto en el K-Fold simple, y con su práctica desaparición (+0,7%) al generalizar a territorios nuevos. Los "factores principales" que llegan al dashboard son, por tanto, mayoritariamente factores de patología, no de territorio -así debe comunicarse también en la sección 6, para no sugerir al usuario final una capacidad predictiva territorial que la validación no respalda.

6. Despliegue (Deployment)

6.1 Dashboard: mapa/ranking de presión asistencial por CCAA y patología (2023) + panel de tendencia nacional 2014-2023

El dashboard se organiza en dos bloques, coherentes con la separación ya establecida entre la foto 2023 y la serie histórica (secciones 2 y 3):

Bloque 1 - Índice de presión asistencial (2023). Consume directamente `indice_presion_dashboard.csv` (generado en `tfm_04_modelado.ipynb`): 360 filas con `ccaa`, `patologia_nombre`, `altas_por1000hab_camras`, `score_presion_0_100` y `factores_principales`. Se presenta como:

- Un ranking/mapa por CCAA, agregando el score por territorio (misma lectura que la Figura 3.1: Comunitat Valenciana, Madrid y Balears en cabeza; Canarias, Ceuta y Melilla y Extremadura al final).
- Un ranking por patología, mostrando qué combinaciones patología × CCAA concentran mayor score (el ejemplo real ya calculado: Comunitat Valenciana + enfermedades del sistema circulatorio, score 100,0).
- Para cada segmento seleccionado, sus 2 factores principales en lenguaje no técnico (p. ej. "influye sobre todo la tasa de fallecimiento típica de esta patología a nivel nacional, y en menor medida el personal sanitario por 1.000 habitantes de esta comunidad").

Bloque 2 - Tendencia nacional (2014-2023). Reutiliza las Figuras 2.5.1 a 2.5.4 del EDA de la sección 2 (altas totales, estancia media y ocupación, dotación de camas, urgencias; Ministerio de Sanidad, 2025), con la ruptura 2020-2021 señalizada visualmente. Se presenta como panel de contexto, no filtrable por CCAA ni por patología, porque la fuente no lo permite (sección 2.2).

Restricción de diseño explícita, derivada de la sección 5.4: el dashboard no debe presentar el score como una predicción validada de presión futura por territorio. La evaluación (sección 5) mostró que la contribución territorial al índice, aunque real, es modesta y no generaliza con solidez a CCAA nunca vistas (+0,7% de mejora bajo GroupKFold por CCAA; Roberts et al., 2017). El dashboard comunica el score como lo que es: un ranking descriptivo de 2023, construido con un modelo cuyos pesos están mayoritariamente determinados por el perfil clínico de la patología, no por el territorio.

6.2 Público objetivo y cómo se comunica el resultado

Público objetivo, heredado de la sección 1 (Business Understanding):

- Dirección médica de área sanitaria / planificación de red.
- Gestión de camas y dotación de recursos.

Cómo se comunica el resultado:

- El score de 0 a 100 se presenta siempre como índice de priorización para planificación estructural, nunca como una alerta operativa ni como una decisión sobre un paciente concreto - coherente con el objetivo de negocio definido desde la sección 1 ("apoyo a la planificación estructural, no a la operativa diaria").
- Los "factores principales" se comunican en lenguaje de negocio (p. ej. "mortalidad típica de la patología", "dotación de personal de la comunidad"), nunca como nombres de variable técnicos ni como coeficientes (Lundberg y Lee, 2017).
- Se incluye, de forma visible y no como nota a pie de página, la advertencia de que la mayor parte del score refleja el perfil clínico de la patología, y que la componente territorial, aunque real, es la de menor peso - evitando así que un usuario no técnico interprete el ranking entre CCAA como una diferencia de capacidad de gestión más marcada de lo que los datos sostienen.
- Ninguna pantalla del dashboard permite filtrar o consultar por paciente individual: toda la capa gold está agregada a nivel patología × CCAA, y así se mantiene en el producto final.

6.3 Mantenimiento y actualización

El INE (2024) y el Ministerio de Sanidad (2025) publican estas ocho fuentes con periodicidad anual. El pipeline de la sección 3 (`tfm_pipeline_seccion3.py`) está diseñado para volver a ejecutarse sobre la publicación de 2024 sin cambios estructurales, salvo dos puntos de atención documentados:

- Los desplazamientos de fila de cabecera (`header_row_idx`) de `Tablas_CCAA_2023.xlsx` podrían variar de un año a otro si el INE reestructura alguna hoja; se recomienda revalidar la localización dinámica de cabeceras (ya implementada en el punto 3.2) antes de dar por buena la ejecución.
- Los nombres de territorio deberían seguir casando con `normalize_ccaa()`, pero conviene revalidar el conteo de 18 unidades territoriales tras cada actualización (la propia función ya incluye un `assert` para esto).

Una oportunidad de mantenimiento a medio plazo, no disponible hoy: cada publicación anual adicional de `Alta_Diagnostico_Provincia` es, en sí misma, una nueva foto transversal patología × CCAA. Acumulando varios años de esta misma fuente (2023, 2024, 2025...), sería posible construir de forma orgánica el panel CCAA × varios años que hoy no existe (sección 2.2) - sin depender de fuentes nuevas, simplemente acumulando ejecuciones sucesivas de este mismo pipeline. Es una vía de evolución natural del proyecto, documentada aquí y retomada en 6.4 y 7.3.

6.4 Extensiones futuras

Toda extensión queda condicionada a la disponibilidad de fuentes reales adicionales, nunca a completar huecos con datos sintéticos - principio metodológico del proyecto desde la sección 1:

Extensión	Condición para activarla
Score de riesgo de reingreso a 30 días (Anexo C, M3)	Disponibilidad de iCMBD (o equivalente) como indicador real agregado; mientras la tasa de reingreso no proceda de una fuente real, no se entrena (ver Anexo C)
Score de presión de derivación multianual (Anexo C, M2)	Un fichero con serie temporal de traslados por CCAA, hoy inexistente a esa granularidad
Panel CCAA × varios años para el índice de presión	Acumulación de publicaciones anuales sucesivas de Alta_Diagnostico_Provincia (ver 6.3) - la única extensión de esta lista que no depende de una fuente nueva, solo del paso del tiempo
Desagregación por sexo	Ya disponible en las fuentes actuales (bloques "Hombres"/"Mujeres" descartados en 3.2/3.7 por alcance, no por falta de dato)
Explicabilidad por segmento con modelos alternativos	Contraste de SHAP-GBR frente a coeficientes Ridge ya calculado (sección 4.5); ampliable si se incorpora una fuente con mayor volumen de observaciones que reduzca el riesgo de sobreajuste señalado en 5.5

7. Conclusiones y limitaciones del TFM

7.1 Qué demuestra el proyecto y qué no

Qué demuestra:

- Que es posible construir, con datos 100% reales y públicos del INE (2024) y el Ministerio de Sanidad (2025), una capa gold integrada y validada (360 filas, 0 nulos, desviación de 0,11% frente a la cifra oficial de altas) que cruza diagnóstico y territorio para el año 2023 - algo que ninguna de las ocho fuentes ofrece por separado.
- Que el índice de presión asistencial resultante separa patologías de forma clara y consistente (el perfil clínico nacional explica un R^2 de $\sim 0,91$ sobre la variable objetivo).
- Que, una vez corregido el sesgo de validación (GroupKFold por CCAA; Roberts et al., 2017), existe una contribución territorial real pero modesta (+0,7% de mejora en MAE), concentrada en `personal_por1000` y `rotacion_sns`.
- Que un modelo de este tipo puede documentarse con la misma metodología (CRISP-DM; Chapman et al., 2000), reproducibilidad (script + notebook ejecutados sin errores) y honestidad crítica que exigiría un entorno productivo real.

Qué NO demuestra:

- No demuestra capacidad de generalización territorial robusta: bajo la validación correcta, el modelo apenas mejora sobre predecir con la media histórica de cada patología.
- No demuestra capacidad de forecasting: el bloque de tendencia nacional 2014-2023 es descriptivo, con solo 10 puntos anuales, insuficientes para proyectar con garantías (sección 4.3).
- No demuestra ni evalúa riesgo de reingreso individual ni derivación multianual: quedan como diseño conceptual no implementado (Anexo C), condicionados a fuentes que hoy no existen públicamente.
- No establece relaciones causales: la asociación entre `personal_por1000` y la presión asistencial no implica que aumentar personal reduzca la presión - el modelo no distingue causalidad de asociación (sección 5.5).

7.2 Limitaciones de fuente como resultado central del TFM

La limitación de granularidad de las fuentes públicas -ninguna cruza diagnóstico + territorio + tiempo simultáneamente- no es una nota al margen de este trabajo: es el hallazgo que determinó su diseño desde la fase de Data Understanding (sección 2) y

que se sostiene, verificado, hasta la evaluación final (sección 5). El proyecto documenta esta limitación de forma explícita en cada fase en la que resulta relevante:

En la selección de alcance (sección 1.4): un único módulo (índice estructural 2023) en vez de los tres módulos inicialmente contemplados.

En la preparación de datos (sección 3.5): motivo de alta, urgencia y estancia media solo a nivel nacional.

En el modelado (sección 4.1): exclusión de variables por fuga de información derivada de la propia estructura del gold (Kaufman et al., 2012).

En la evaluación (sección 5.3-5.4): la corrección del sesgo de validación que reveló que la señal territorial es más débil de lo que sugería una primera aproximación.

Tratar la limitación de fuente como resultado, y no como excusa, es lo que permite que las conclusiones de este TFM sean defendibles: cada afirmación está acotada exactamente a lo que los datos reales disponibles pueden sostener.

7.3 Líneas futuras

Acumulación temporal orgánica (ver 6.3): repetir la ejecución del pipeline en años sucesivos para construir, con el tiempo, el panel CCAA × varios años hoy inexistente - la única línea futura que no depende de una fuente nueva.

Incorporación de iCMBD (o equivalente) para activar el diseño conceptual de riesgo de reingreso a 30 días (Anexo C, M3), manteniendo la corrección metodológica ya documentada (identificador de paciente real, validación por grupos, no por episodio_id; Roberts et al., 2017).

Fuente de traslados con desagregación territorial, para activar el diseño conceptual de presión de derivación (Anexo C, M2), hoy limitado por la ausencia de esa desagregación en Alta_Motivo_ingreso (INE, 2024).

Desagregación por sexo, ya disponible en las fuentes actuales pero descartada por alcance (sección 3.7), como extensión de bajo coste sobre el mismo pipeline.

Mayor volumen de observaciones antes de reconsiderar modelos con más parámetros (por ejemplo, dummies de patología o CCAA, descartadas en 4.4 por riesgo de sobreajuste sobre 360 filas): cada año adicional acumulado (ver línea 1) reduce ese riesgo y amplía las alternativas de modelado disponibles.

Bibliografía

- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.
<https://doi.org/10.1214/aos/1013203451>
- Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.
<https://doi.org/10.1007/978-0-387-84858-7>
- Hoerl, A. E., y Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55-67.
<https://doi.org/10.1080/00401706.1970.10488634>
- Hurlbert, S. H. (1984). Pseudoreplication and the design of ecological field experiments. *Ecological Monographs*, 54(2), 187-211.
<https://doi.org/10.2307/1942661>
- Instituto Nacional de Estadística. (2024). *Encuesta de Morbilidad Hospitalaria 2023* [Conjunto de datos]. <https://www.ine.es>
- Kaufman, S., Rosset, S., Perlich, C., y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), Artículo 15.
<https://doi.org/10.1145/2382577.2382579>
- Ley 16/2003, de 28 de mayo, de cohesión y calidad del Sistema Nacional de Salud. (2003). *Boletín Oficial del Estado*, (128), 20567-20588.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., y Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56-67. <https://doi.org/10.1038/s42256-019-0138-9>
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En I. Guyon et al. (Eds.), *Advances in Neural Information Processing Systems 30* (pp. 4765-4774). Curran Associates.
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61.
<https://doi.org/10.25080/Majora-92bf1922-00a>
- Ministerio de Sanidad. (2025). *Estadística de Establecimientos Sanitarios con Régimen de Internamiento (ESCRI): Tablas por comunidad autónoma 2023 y series de actividad y dotación 2014-2023* [Conjunto de datos]. <https://www.sanidad.gob.es>

Organización Mundial de la Salud. (2019). *International statistical classification of diseases and related health problems* (10.^a rev.).
<https://icd.who.int/browse10/2019/en>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillerá-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., y Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913-929. <https://doi.org/10.1111/ecog.02881>

Anexos

A. Diccionario de datos completo. B. Detalle de las 8 fuentes originales y su ficha técnica (INE/Sanidad). C. Diseño conceptual no implementado (derivación multianual, riesgo de reingreso) - heredado de las Entregas 3-4, condicionado a nuevas fuentes.

Anexo A. Diccionario de datos completo

Este anexo documenta las 45 variables de la capa gold principal, gold_presion_asistencial_2023.csv (360 filas = 20 patologías × 18 territorios, clave primaria (anio, ccaa, patologia_cie10), 0 valores nulos), elaborada a partir de INE (2024) y Ministerio de Sanidad (2025). Las 34 variables de contexto estructural (bloques B a D) coinciden con las de gold_contexto_ccaa_2023.csv (18 filas, clave primaria ccaa); las variables de los bloques E y F son exclusivas de la capa principal.

Para cada campo se indica el nivel real de la variable -territorial (varía por CCAA), nacional (mismo valor para las 18 CCAA dentro de una misma patología) o derivado (calculado en el propio pipeline)- porque es la distinción que condiciona su uso correcto en el modelado de la sección 4 (ver limitación documentada en el punto 3.5).

A.1. Identificadores y variable base

Campo	Tipo	Descripción	Fuente	Nivel
anio	int	Año de referencia de todos los registros (2023)	-	-
ccaa	str	Comunidad autónoma o ciudad autónoma (17 CCAA + Ceuta y Melilla combinadas en una unidad)	Alta_Diagnostico_Provincia / Tablas_CCAA_2023	Territorial
patologia_cie10	str	Código de capítulo CIE-10, 4 dígitos terminados en 00 (p. ej. 1100)	Alta_Diagnostico_Provincia	Real
patologia_nombre	str	Nombre descriptivo del capítulo diagnóstico	Alta_Diagnostico_Provincia	Real
altas	float	Número de altas hospitalarias de esa patología en esa CCAA (2023)	Alta_Diagnostico_Provincia	Real, territorial - variable base del índice

A.2. Contexto estructural de CCAA -hospitales y dotación de camas

Campo	Tipo	Descripción	Nivel
hospitales_sns	int	Nº de hospitales de dependencia pública-SNS en la CCAA	Territorial
hospitales_privados	int	Nº de hospitales privados en la CCAA	Territorial
hospitales_total	int	Nº total de hospitales en la CCAA	Territorial
camas_instaladas_sns	int	Camas instaladas del subsector público-SNS	Territorial
camas_instaladas_total	int	Camas instaladas totales (público + privado)	Territorial
camas_instaladas_por1000	float	Camas instaladas totales por 1.000 habitantes	Territorial

Campo	Tipo	Descripción	Nivel
camas_funcionamiento_sns	int	Camas en funcionamiento del subsector público-SNS	Territorial
camas_funcionamiento_total	int	Camas en funcionamiento totales -denominador de altas_por1000hab_camias (A.7)	Territorial
camas_funcionamiento_por1000	float	Camas en funcionamiento totales por 1.000 habitantes	Territorial
pct_camias_sns	float	% de camas en funcionamiento que son del subsector público-SNS (rango observado: 69,8%-100%)	Territorial

A.3. Contexto estructural de CCAA -personal

Campo	Tipo	Descripción	Nivel
personal_jornada_completa	int	Personal vinculado a jornada completa	Territorial
personal_jornada_parcial	int	Personal vinculado a jornada parcial	Territorial
personal_vinculado	int	Personal vinculado total (completa + parcial)	Territorial
personal_por1000	float	Personal vinculado por 1.000 habitantes	Territorial

A.4. Contexto estructural de CCAA -frecuentación e indicadores de hospitalización

Campo	Tipo	Descripción	Nivel
ingresos_total_ccaa	int	Nº total de ingresos hospitalarios de la CCAA (todas las patologías)	Territorial
ingresos_por1000	float	Ingresos totales por 1.000 habitantes	Territorial
altas_total_ccaa	int	Nº total de altas de la CCAA (todas las patologías) - denominador de altas_pct_sobre_ccaa (A.7)	Territorial
altas_por1000	float	Altas totales por 1.000 habitantes	Territorial
estancias_total_ccaa	int	Nº total de estancias-día de la CCAA	Territorial
estancias_por1000	float	Estancias totales por 1.000 habitantes	Territorial
estancia_media_sns	float	Estancia media (días), subsector público-SNS	Territorial
ocupacion_sns	float	Índice de ocupación, subsector público-SNS (proporción 0-1)	Territorial
rotacion_sns	float	Índice de rotación de camas, subsector público-SNS	Territorial
mortalidad_sns	float	Mortalidad intrahospitalaria, subsector público-SNS (proporción 0-1)	Territorial
estancia_media_priv	float	Estancia media (días), subsector privado	Territorial
ocupacion_priv	float	Índice de ocupación, subsector privado	Territorial
rotacion_priv	float	Índice de rotación, subsector privado	Territorial
mortalidad_priv	float	Mortalidad intrahospitalaria, subsector privado	Territorial

Nota: se toman los indicadores del subsector público-SNS como valor de referencia de la CCAA en el análisis (ver punto 3.3), dado que concentra entre el 69,8% y el 100% de las camas en funcionamiento según el territorio; los del subsector privado se conservan como variables adicionales, no como sustituto.

A.5. Contexto estructural de CCAA -urgencias

Campo	Tipo	Descripción	Nivel
urgencias_total	int	Nº total de urgencias atendidas en la CCAA	Territorial
pct_urgencias_sns	float	% de urgencias atendidas en centros del SNS	Territorial
urgencias_por1000	int	Urgencias atendidas por 1.000 habitantes	Territorial
pct_urgencias_ingresadas	float	% de urgencias que terminan en ingreso hospitalario	Territorial
presion_urgencias	float	Indicador de presión de urgencias de la CCAA (proporción 0-1)	Territorial

A.6. Contexto nacional por patología (Alta_Motivo_ingreso, Alta_Urgencia_ingreso, Estancia_media)

Campo	Tipo	Descripción	Nivel
tasa_traslado_nacional	float	% de altas de esa patología cuyo motivo fue el traslado a otro centro (rango: 1,0%-13,3%)	Nacional - mismo valor en las 18 CCAA para una misma patología (ver 3.5)
pct_fallecimiento_nacional	float	% de altas de esa patología cuyo motivo fue el fallecimiento (rango: 0,004%-13,1%)	Nacional
pct_urgente_nacional	float	% de ingresos de esa patología que fueron urgentes (rango: 43,7%-80,6%)	Nacional
estancia_media_dias_nacional	float	Estancia media (días) de esa patología a nivel nacional (rango: 3,0-54,3 días)	Nacional

A.7. Variables derivadas

Campo	Tipo	Cálculo	Nivel
altas_pct_sobre_ccaa	float	altas / altas_total_ccaa -peso relativo de la patología dentro de su CCAA	Derivado, territorial
altas_por1000hab_camars	float	altas / camas_funcionamiento_total -proxy de presión estructural de esa patología sobre la dotación instalada de la CCAA (no es ocupación en tiempo real)	Derivado, territorial
traslados_estimados_nacional	float	altas × tasa_traslado_nacional -estimación indicativa de traslados esperables si la tasa nacional de la patología se aplicase a esa CCAA. No es un dato real de traslados por territorio (no existe en ninguna fuente): es la tasa nacional aplicada a un volumen territorial real, y debe leerse y comunicarse como tal	Derivado, mixto (volumen real × tasa nacional)

Nota de uso para el modelado (sección 4): únicamente los campos marcados como territoriales en las columnas "Nivel" aportan variación real entre comunidades autónomas para una misma patología. Los campos marcados como nacionales son constantes por patología en las 18 filas correspondientes y deben tratarse como contexto de la patología, nunca como una diferencia territorial observada.

Anexo B. Detalle de las 8 fuentes originales y su ficha técnica (INE/Sanidad)

Las ocho fuentes proceden de la Encuesta de Morbilidad Hospitalaria (EMH; INE, 2024) y de la Estadística de Establecimientos Sanitarios con Régimen de Internamiento (ESCRI; Ministerio de Sanidad, 2025), ambas de acceso abierto y público, sin restricciones de descarga ni requisitos de autorización. Para cada fichero se indica su ficha técnica y el papel exacto que desempeña en el proyecto (capa gold del índice, bloque de tendencia nacional, o excluido).

Fichero	Organismo / operación estadística	Hoja(s) interna(s)	Periodo	Nivel geográfico	Papel en el TFM
Alta_Diagnostico_Provincia.xlsx	INE - EMH (INE, 2024)	tabla-74901	2023	Nacional, CCAA y provincia	Capa gold (sección 3) -variable base del índice (altas); único cruce diagnóstico × territorio disponible
Alta_Motivo_ingreso.xlsx	INE - EMH (INE, 2024)	tabla-74880	2023	Nacional únicamente	Capa gold -contexto nacional por patología (tasa_traslado_nacional, pct_fallecimiento_nacional)
Alta_Urgencia_ingreso.xlsx	INE - EMH (INE, 2024)	tabla-74877	2023	Nacional únicamente	Capa gold -contexto nacional por patología (pct_urgente_nacional)
Estancia_media.xlsx	INE - EMH (INE, 2024)	tabla-74890	2023	Nacional únicamente	Capa gold -contexto nacional por patología (estancia_media_dias_nacional)
Altas_Diagnostico_principal.xlsx	INE - EMH (INE, 2024)	tabla-74878	2023	Nacional únicamente	Excluida de la capa gold -altas por diagnóstico × grupo de edad; redundante con la desagregación por edad ya trabajada en el EDA de la sección 2 (Figuras 2.6.4-2.6.5), sin aportar cruce territorial nuevo
Tablas_CCAA_2023.xlsx	Ministerio de Sanidad - ESCRI (2025)	24 hojas (1.1 a 7.3, más índice y gráficos); se usan 1.1, 2.1, 4.1, 5.1, 5.2 y 6.4	2023	CCAA	Capa gold -contexto estructural territorial (hospitales, camas, personal, frecuentación, indicadores de hospitalización, urgencias)
Actividad_Evolucion_2014-2023.xlsx	Ministerio de Sanidad - ESCRI (2025)	13 hojas (TABLA 3.1 3.2 a TABLA 3.20)	2014-2023	Nacional	Bloque de tendencia (sección 2) - altas totales, estancia media, ocupación, urgencias
Dotacion_Evolucion_2014-2023.xlsx	Ministerio de Sanidad - ESCRI (2025)	10 hojas (TABLA 1.1 1.2 a TABLAS 1.15)	2014-2023	Nacional	Bloque de tendencia (sección 2) - dotación de camas públicas y privadas

Notas comunes a las ocho fuentes:

- Tipo de acceso: abierto y público, sin registro ni pago; descarga directa en formato Excel desde las webs del INE (ine.es) y el Ministerio de Sanidad (sanidad.gob.es).
- Estabilidad: fuentes oficiales de publicación periódica (anual), con alta estabilidad de formato y mantenimiento garantizado por el organismo emisor.

- Codificación de diagnóstico: CIE-10 (OMS, 2019), jerárquica (capítulo/subcapítulo) en la misma columna, en las cinco fuentes que incluyen diagnóstico.
- Valores de secreto estadístico: representados como .. en las celdas de recuento bajo; tratados como ausentes en todo el pipeline (sección 3.2), nunca como cero.
- Particularidad estructural: todas las hojas de Tablas_CCAA_2023.xlsx, Actividad_Evolucion_2014-2023.xlsx y Dotacion_Evolucion_2014-2023.xlsx repiten el título completo del libro antes de la tabla real, con un número de filas de cabecera distinto por hoja -de ahí la necesidad de localización dinámica de cabecera documentada en la sección 3.2.

Anexo C. Diseño conceptual no implementado

Este anexo conserva, con las correcciones metodológicas ya incorporadas en la revisión de la Entrega 4, el diseño de los dos módulos descartados del alcance final del MVP (sección 1.4): M2 -presión de derivación y M3 -riesgo de reingreso a 30 días. Ninguno de los dos se entrena, valida ni implementa en este TFM; se documentan para activarse en el futuro si aparecen las fuentes reales que hoy no existen (ver sección 6.4 y 7.3).

C.1. Por qué se descartan del MVP

Tras la validación fichero a fichero de las 8 fuentes reales (sección 2), ninguna ofrece:

- Un panel de traslados con desagregación territorial (necesario para M2): Alta_Motivo_ingreso solo existe a nivel nacional (sección 3.5; INE, 2024).
- Un identificador de paciente o episodio, ni un indicador de reingreso agregado real (necesario para M3): ninguna de las 8 fuentes lo contiene.

Ambos módulos exigirían, para sostenerse con las fuentes actuales, recurrir a datos sintéticos -algo que el proyecto excluye explícitamente como principio metodológico desde la sección 1.

C.2. M2 -Presión de derivación

Planteamiento: regresión (Ridge / Gradient Boosting Regressor; Hoerl y Kennard, 1970; Friedman, 2001) sobre tasa_traslado, con predictoras mortalidad_intrahosp_pct, desviacion_estancia, camas_totales_ccaa (normalizada por altas totales de la CCAA) y anio.

Corrección metodológica incorporada: camas_totales_ccaa es contexto estructural anual, nunca debe leerse ni comunicarse como disponibilidad real de camas para recomendar una derivación concreta. El score sería un índice de priorización de planificación, no una recomendación operativa sobre un paciente o

traslado individual -mismo principio de comunicación ya aplicado al índice de presión asistencial sí implementado (sección 6.2).

Datos de salida (conceptual):

Campo	Descripción	Tipo
patologia_cie10, ccaa_codigo, anio	Unidad predicha	str/int
score_presion_derivacion	Índice de 0 a 100; mayor valor = mayor presión estructural de derivación	float
factores_principales	2-3 variables con mayor peso en el score	list[str]

Validación (conceptual): leave-one-year-out (validación cruzada dejando un año fuera, dado el bajo número de años disponibles); métrica R^2 y MAE sobre tasa_traslado; baseline = media histórica de tasa_traslado por patología, sin CCAA.

Condición de activación: un fichero real con serie temporal de traslados desagregada por CCAA, hoy inexistente.

C.3. M3 -Riesgo de reingreso a 30 días

Planteamiento: regresión (Gradient Boosting Regressor; Friedman, 2001) sobre tasa_reingreso_30d, con explicabilidad SHAP (Lundberg y Lee, 2017), predictoras desviacion_estancia, mortalidad_intrahosp_pct, pct_ingreso_urgente, grupo_edad (codificada ordinalmente) y patologia_cie10.

Correcciones metodológicas obligatorias, incorporadas tras la revisión de la Entrega 4:

4. **Validación por paciente real, no por episodio.** Si el diseño llegara a nivel de episodio individual, separar por episodio_id no evita que varios episodios de la misma persona aparezcan a la vez en entrenamiento y prueba, lo que infla artificialmente las métricas -exactamente el mismo tipo de fuga por pseudorréplica que se corrigió en la evaluación del índice sí implementado (sección 5.1, GroupKFold; Hurlbert, 1984; Roberts et al., 2017). La validación deberá ser por grupos (GroupKFold sobre identificador de paciente real) y, preferiblemente, también temporal.
5. **Riesgo de circularidad con etiqueta sintética.** Si la tasa de reingreso se completase alguna vez con dato sintético para ganar granularidad, el modelo podría limitarse a reproducir las reglas usadas para generar esa etiqueta, obteniendo métricas altas sin validez clínica real (Kaufman et al., 2012). Por eso, mientras la variable objetivo no proceda de un indicador real agregado (iCMBD), M3 no se entrena -ni siquiera como prueba técnica sin declarar explícitamente que se trata de una validación del prototipo, nunca de evidencia de capacidad asistencial real.

Se descarta, como ya se documentó en la Entrega 3, un clasificador binario individual: exigiría una etiqueta de reingreso por paciente que ninguna fuente pública ofrece sin recurrir a datos sintéticos.

Datos de salida (conceptual):

Campo	Descripción	Tipo
patologia_cie10, grupo_edad, ccaa_codigo, anio	Unidad predicha	str/int
score_riesgo_reingreso	Índice de 0 a 100; mayor valor = mayor riesgo relativo de reingreso en ese segmento	float
factores_principales	2-3 variables con mayor peso en el score	list[str]

Consumo previsto: ranking/mapa por CCAA y patología, nunca una recomendación sobre un paciente individual identificado - el dashboard etiquetaría explícitamente estos paneles como "índices de priorización a nivel de segmento", el mismo lenguaje ya aplicado al panel sí implementado (sección 6.2).

Condición de activación: disponibilidad de iCMBD (o equivalente) como indicador real agregado de reingreso, con la granularidad de patología y CCAA confirmada.

C.4. Riesgos específicos de M2/M3 (conceptual)

Riesgo	Descripción	Plan de contingencia
Circularidad con etiqueta sintética (M3)	El modelo podría reproducir las reglas de generación de una etiqueta sintética en vez de demostrar validez clínica (Kaufman et al., 2012)	M3 no se entrena mientras la variable objetivo no proceda de iCMBD; si se explorase con dato sintético por motivos técnicos, el resultado se presentaría como validación técnica del prototipo, nunca como evidencia asistencial real
Confusión entre severidad clínica y capacidad de red (M2)	El modelo podría atribuir a "complejidad de la patología" lo que en realidad es falta de camas en una CCAA concreta	Mismo riesgo ya identificado y tratado explícitamente en el índice sí implementado (sección 5.5)
Fuga de información entre episodios del mismo paciente (M3)	Separar por episodio_id no impide que dos episodios de la misma persona caigan uno en entrenamiento y otro en prueba (Roberts et al., 2017)	Validación por grupos sobre identificador de paciente real, combinada con separación temporal
Granularidad real de iCMBD	El indicador de reingreso puede no desagregar por patología y CCAA simultáneamente	Simplificar a la desagregación que sí ofrezca el indicador, documentando la pérdida de resolución
Bajo volumen en combinaciones patología × CCAA × edad	Tasas inestables, riesgo de sobreajuste	Umbral mínimo de altas por celda; agrupación de patologías poco frecuentes -mismo tipo de riesgo ya observado en el índice sí implementado (sección 5.5, Ceuta y Melilla y Rioja)

C.5. Condición general de activación

Ambos módulos solo se activarían tras confirmar la granularidad real de las fuentes que hoy no están disponibles (iCMBD para M3, traslados territoriales para M2), y con

el MVP (índice de presión asistencial, secciones 3 a 6) ya entregado y evaluado - aplicando desde el primer momento las correcciones de validación por grupos, nunca por episodio simple, recogidas en C.3.